

Mensuração de Teste A/B - Um exemplo prático para campanhas de marketing e pricing

Gabriela Macedo

2025-05-01

Table of contents

1	Objetivo do projeto	4
2	Estrutura do Estudo	5
2.1	Estrutura do Dataset	5
2.2	Metodologia Estatística	6
2.2.1	Etapas:	7
2.3	Ferramentas Utilizadas	7
3	Você define a amostra	8
3.1	Contexto	8
3.1.1	Cenário Atual:	8
3.1.2	Resultados Prévios	8
3.1.3	Conversão	9
3.2	Efeito Mínimo Detectável (EMD):	9
3.2.1	Cálculo do Efeito Mínimo Detectável (EMD) para 2 grupos	10
3.2.2	Um pouco mais de EMD	11
3.2.3	Significância Estatística:	11
3.2.4	Taxa de Conversão:	11
4	Mensurando os resultados	13
4.1	Cenário	13
4.2	Base de dados	13
4.3	Mensuração dos resultados	13
4.3.1	Import das bibliotecas	14
4.3.2	Avalia o tamanho da amostra	14
4.3.3	Amostra mínima	15
4.3.4	Análise do resultado do teste	16
4.3.5	Delta Conversão	17
4.3.6	Lift	18
4.3.7	Incremento de contas	18
4.3.8	Incremento de gasto	19
4.3.9	Incremento de faturamento	19
4.3.10	Análise da variável contínua	20
4.4	Avaliação completa dos resultados	21
4.4.1	Qual decisão tomar?	23

4.4.2	Tabela de avaliação dos resultados	25
5	Analisando diversos perfis	26
5.1	Um pouco mais de contexto	26
5.1.1	Import das bibliotecas	26
5.1.2	Pró-Memória	27
6	Anexos	30
7	Grupo Controle Universal	31
7.1	Porque ter um grupo controle?	31
7.2	Como criar o seu grupo controle	31
7.3	Como aplicar na segmentação de uma campanha	34
	Referências	36
	Contato	37

1 Objetivo do projeto

O propósito principal estruturar e automatizar a análise de testes A/B realizados em diferentes contextos de negócios, especialmente campanhas de marketing, produtos de crédito, seguros e iniciativas de ativação de clientes. A proposta é ir além da simples comparação de conversões, incluindo métricas como:

- Taxas de conversão
- Incremento de contas
- Teste de hipótese (z-test para proporções)
- Lift absoluto e relativo
- Significância estatística
- Cálculo de Efeito Mínimo Detectável (EMD)
- Poder estatístico e tamanho de amostra necessário

2 Estrutura do Estudo

Quando realizamos testes de comparação entre grupo, sempre buscamos comparar os desempenhos entre eles, por exemplo:

- **Campanhas de marketing:** Qual anuncio converte mais? O anúncio A ou B? Qual grupo FL_ATIVADO um produto após uma ação grupo A, grupo B ou controle (que não recebeu a ação)?
- **Cartões de Crédito:** Testar se oferecer 1% de cashback em todas as compras ou 2% em categorias específicas (como supermercados) aumenta a ativação de novos cartões.
- **Seguros:** Comparar o impacto de mensagens focadas na proteção da família versus benefícios financeiros para aumentar as cotações de seguros de vida.
- **Empréstimos:** Avaliar se taxas de juros personalizadas com base no perfil de crédito do cliente aumentam a aceitação de propostas de empréstimo em comparação com uma taxa padrão.
- **Educação Online:** Testar se enviar e-mails motivacionais semanais ou lembretes automáticos quando o aluno fica inativo aumenta a finalização dos cursos em comparação a não enviar nenhuma comunicação.
- **Aplicativos de Saúde:** Comparar o impacto de notificações gamificadas com desafios versus notificações informativas personalizadas para aumentar o uso diário do aplicativo, em relação a não enviar notificações.
- **E-commerce de Moda:** Avaliar se oferecer desconto progressivo por valor gasto ou frete grátis acima de determinado valor aumenta o ticket médio das compras, comparado ao cenário sem promoções.

2.1 Estrutura do Dataset

Todos os exemplos terão basicamente 4 métricas em comum, elas podem se referir ao total de uma campanha, ou de subgrupos dentro do seu estudo.

- **Qtde Teste:** Total de clientes selecionados para participar de uma ação de ativação de cartão

- **Qtde Conversao Teste** : Total de clientes selecionados que ativaram o cartão em um determinado período de tempo
- **Qtde Controle** : Grupo de clientes com o **mesmo perfil** dos clientes selecionados para ação, porém não receberam nenhum estímulo para conversão (ativação).
- **Qtde Conversao Controle** : Total de cliente possuem o mesmo perfil do grupo selecionado e que não participou da ação e ativou o cartão no mesmo período de tempo do grupo selecionado

Importante ressaltar, que não precisamos nos restringir a 2 grupos, podemos fazer um teste A/B/C e Controle, etc, mas fique atento se terá amostra o suficiente para realizar todas as comparações.

A partir dessas colunas, serão calculadas métricas adicionais, como:

- `taxa_conv_teste`
- `taxa_conv_controle`
- `delta_conv` (diferença bruta entre as conversões)
- `incremento_contas` (efeito incremental estimado)
- `lift` (taxa relativa de melhoria)
- `resultado_conv` (resultado do teste de hipótese)

A partir dessas métricas, iremos usar os testes de hipótese para avaliar se realmente o resultado obtido é significativo em termos estatísticos.

Importante Não descarte sua mensuração por não obter resultados. Investigue o que aconteceu, há algumas coisas a serem investigadas:

- O experimento aconteceu de maneira correta?
- Seu grupo controle realmente é comparável com o grupo de teste?
- Faltou volumetria?
- Sua oferta é realmente boa?

Não ter resultado, também é um resultado!!!

2.2 Metodologia Estatística

Para avaliar a significância das diferenças observadas entre o grupo controle e o grupo teste, utilizamos o **teste z para duas proporções** via `statsmodels.stats.proportion.proportions_ztest`.

2.2.1 Etapas:

1. Cálculo da taxa de conversão por grupo
2. Diferença bruta e percentual (lift)
3. Teste de hipótese (H : taxas iguais)
4. Interpretação da significância (p-valor)
5. Construção de métricas de impacto, como contas incrementais

Além disso, há suporte ao cálculo do Efeito Mínimo Detectável (EMD), baseado em:

- Conversão esperada
- Poder do teste (geralmente 80%)
- Nível de significância (geralmente 5%)

Com uso da função `NormalIndPower` do `statsmodels`, é possível determinar o **tamanho de amostra necessário** para detectar um determinado efeito com o poder especificado.

2.3 Ferramentas Utilizadas

- `pandas`: manipulação de dados
- `scipy.stats` e `statsmodels`: testes estatísticos e cálculo de poder
- `openpyxl`: exportação dos resultados para Excel (caso desejado)

3 Você define a amostra

3.1 Contexto

Você é o analista do Estúdio Biela e vai iniciar a análise de desempenho da nova campanha digital.

Sua missão é criar uma estratégia de comunicação que aumente a conversão em clientes das campanhas realizadas no site.

3.1.1 Cenário Atual:

*dados fictícios

A campanha atinge uma média de **10.000 usuários por dia**. Esse é o seu ponto de partida: o alcance bruto.

Você sabe que:

- **5%** dos usuários clicam no banner — essa é a **taxa de clique (CTR)**.
- Dos que clicam, **30%** realizam uma compra — essa é a **taxa de conversão após o clique**.
- Logo: $\text{Conversão} = \text{Alcance} \times \text{CTR} \times \text{Taxa de Conversão}$
- Ou seja, no cenário atual temos $10000 \times 5\% \times 30\% = 150$ usuários por campanha ou 1,5% dos impactados pelo banner

Agora é hora de aplicar a fórmula de conversão para entender o impacto final da campanha:

3.1.2 Resultados Prévios

```
# Importa bibliotecas
import numpy as np
import pandas as pd
from statsmodels.stats.power import NormalIndPower
from statsmodels.stats.proportion import proportions_ztest, proportion_effectsize
```

```
# Parâmetros iniciais conhecidos de mensurações anteriores
alcance_diario = 10000
ctr = 0.05
conversao_banner = 0.30
```

3.1.3 Conversão

Conversão esperada é de aproximadamente 150 usuários, ou 1,5% da audiência diária (alcance x CTR x taxa de conversão).

```
# Conversão final diária
conversao_final = alcance_diario * ctr * conversao_banner
conversao_final_taxa = conversao_final / alcance_diario
print(f"Conversão final esperada: {conversao_final:.0f} usuários ({conversao_final_taxa:.2%})")
```

Conversão final esperada: 150 usuários (1.50%)

3.2 Efeito Mínimo Detectável (EMD):

Um das primeiras decisões do seu teste é o aumento que você quer na conversão, ou seja:

- Se a taxa atual é 1,5%, uma melhoria de 10% resultaria em 1,65%.

Vamos olhar de outra forma:

Suco de Laranja no Recreio

Você vende suco de laranja na escola. Todo dia, 100 amigos passam pela sua barraquinha, mas só 1 ou 2 amigos compram o suco. Aí você pensa:

“E se eu colocar um canudinho colorido no copo, será que mais amigos vão querer comprar?”

Efeito Mínimo Detectável (EMD) é... É o menor aumento nas vendas que você quer perceber com o seu teste.

Por exemplo:

Hoje, só 2 de 100 amigos compram (isso é 2%).

Você quer saber se o canudo colorido aumenta isso para pelo menos 2,5%.

Esse 0,5% de diferença é o efeito mínimo detectável.

Por que isso é importante?

Porque se o canudo colorido só fizer 1 amigo a mais comprar por sorte, você não pode ter certeza se foi o canudo ou o acaso. Então você escolhe:

“Se não aumentar pelo menos um pouquinho visível (tipo 0,5%), nem vale a pena mudar!”

Em resumo:

EMD é como uma régua: Serve para medir se a diferença entre o antigo e o novo é grande o suficiente para ser notada de verdade, e não só sorte.

3.2.1 Cálculo do Efeito Mínimo Detectável (EMD) para 2 grupos

```
poder_teste = 0.8 #você quer ter uma chance de acertar de 80%
significancia = 0.05

# Supondo que queremos detectar uma melhoria de 10% na taxa de conversão atual
melhoria_esperada = 0.10

conversao_esperada_pos = conversao_final_taxa * (1 + melhoria_esperada)
efeito_minimo_detectavel = conversao_esperada_pos - conversao_final_taxa

# Cálculo do tamanho da amostra necessário
analysis = NormalIndPower()
effect_size = proportion_effectsize(conversao_final_taxa, conversao_esperada_pos)
tamanho_amostra = analysis.solve_power(
    effect_size=effect_size,
    power=poder_teste,
    alpha=significancia,
    ratio=1
)
tamanho_amostra = np.ceil(tamanho_amostra)
tamanho_amostra = np.ceil(tamanho_amostra)

total_amostra = 2 * tamanho_amostra
usuarios_por_grupo_dia = alcance_diario / 2

dias_necessarios = total_amostra / alcance_diario

print(f"\nEfeito mínimo detectável: {efeito_minimo_detectavel:.2%}")
print(f"Tamanho da amostra necessária por grupo: {tamanho_amostra:.0f}")
print(f"Total de usuários necessários (controle + teste): {total_amostra:.0f}")
print(f"Com {alcance_diario} acessos diários, serão necessários aproximadamente {dias_necessarios:.0f} dias")
```

Efeito mínimo detectável: 0.15%

Tamanho da amostra necessária por grupo: 108093

Total de usuários necessários (controle + teste): 216186

Com 10000 acessos diários, serão necessários aproximadamente 21.6 dias de teste.

3.2.2 Um pouco mais de EMD

Pergunta	EMD pequeno?	EMD grande?
“Tenho muito tráfego?”	Sim	Não
“Mudanças pequenas geram muito lucro?”	Sim	Não
“Preciso de uma resposta rápida?”	Não	Sim

Considerações importantes

Tamanho da amostra e EMD: Quanto menor o EMD que você deseja detectar, maior será o tamanho da amostra necessário. Isso ocorre porque detectar diferenças sutis requer mais dados para garantir que os resultados não sejam devidos ao acaso.

Tempo de execução do teste: Um EMD menor também implica em um tempo de teste mais longo, pois é necessário coletar mais dados para atingir o tamanho de amostra adequado.

Equilíbrio entre precisão e recursos: Definir um EMD muito pequeno pode tornar o teste impraticável devido ao tempo e recursos necessários. Por outro lado, um EMD muito grande pode fazer com que melhorias significativas, mas menores que o EMD definido, passem despercebidas.

3.2.3 Significância Estatística:

Valor-p menor que 0.05 (ou 5%) indica que o resultado do teste é estatisticamente significativo, ou seja, há evidências suficientes para afirmar que o grupo teste teve desempenho diferente do controle.

3.2.4 Taxa de Conversão:

Comparada antes e após o teste para avaliar a eficácia real da intervenção (no caso, banner ou outra estratégia adotada).

```

# Simulação dos resultados, aqui você irá usar os resultados obtidos reais
np.random.seed(42)
amostra_controle = np.random.binomial(n=int(tamanho_amostra), p=conversao_final_taxa)
amostra_teste = np.random.binomial(n=int(tamanho_amostra), p=conversao_esperada_pos)

# Teste de hipóteses (Significância estatística)
successes = np.array([amostra_controle, amostra_teste])
nobs = np.array([tamanho_amostra, tamanho_amostra])
stat, pval = proportions_ztest(successes, nobs)

print("\nResultados do teste estatístico:")
print(f"- Conversão grupo controle: {amostra_controle/tamanho_amostra:.2%}")
print(f"- Conversão grupo teste: {amostra_teste/tamanho_amostra:.2%}")
print(f"- Valor de p: {pval:.4f}")

# Interpretação
declaracao = "Estatisticamente significativo" if pval < significancia else "Não significativo"
print(f"Resultado: {declaracao} (alpha = {significancia})")

```

Resultados do teste estatístico:

- Conversão grupo controle: 1.47%
- Conversão grupo teste: 1.68%
- Valor de p: 0.0001

Resultado: Estatisticamente significativo (alpha = 0.05)

4 Mensurando os resultados

Muitas vezes não temos a oportunidade de participar da decisão do volume das amostras, pois muitas campanhas podem ser automatizadas e não atigirem o número que seria adequado, esse pode ser um cenário para campanhas extremamente segmentadas. Mesmo assim, essas precisam ser **MENSURADAS**.

4.1 Cenário

Foi realizada uma campanha que visava fazer o cliente realizar uma compra para ativar o seu cartão. Ou seja, queremos saber se o estímulo de comunicar uma oferta fez com que esse cliente voltasse a transacionar, e como um efeito colateral também podemos avaliar o aumento de gasto.

4.2 Base de dados

Para realizar essa mensuração, você precisa receber uma base que possua as seguintes informações:

Variável	Descrição
CLIENTNUM	Identificador único do cliente
GRUPO_AB	Grupo experimental A/B ao qual pertence (Teste e Controle)
FL_ATIVADO	Flag indicando se o cliente ativou o cartão durante o período da ação
VALOR_GASTO	Valor total gasto pelo cliente

4.3 Mensuração dos resultados

*dados fictícios

Garanta que a separação do grupo_ab tenha sido feita adequadamente antes de iniciar os envios das comunicações, pois caso isso não ocorra, sua mensuração está fadada ao fracasso. No anexo desse conteúdo, há uma sugestão de como criar um grupo controle confiável para sua empresa.

4.3.1 Import das bibliotecas

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import ttest_ind
import numpy as np
from scipy.stats import chi2_contingency
from statsmodels.stats.power import zt_ind_solve_power
import sys
#sys.stdout.reconfigure(encoding='utf-8')
```

```
# Importa o arquivo gerado com os resultados de forma analitica
df = pd.read_csv('./base_ativados_gasto.csv')
df.head()
```

	CLIENTNUM	GRUPO_AB	FL_ATIVADO	VALOR_GASTO
0	1	Controle	0	0.000000
1	2	Teste	0	0.000000
2	3	Teste	0	0.000000
3	4	Teste	0	0.000000
4	5	Teste	1	2185.430535

4.3.2 Avalia o tamanho da amostra

```
# Supondo um efeito mínimo detectável (MDE) de 1 ponto percentual (0.01)
p1 = 0.05          # Conversão esperada no grupo Controle
delta = 0.01       # MDE (efeito mínimo que desejamos detectar)
p2 = p1 + delta    # Conversão esperada no grupo Teste

# Calcular effect size para teste de duas proporções
pooled_var = ((p1 * (1 - p1)) + (p2 * (1 - p2))) / 2
```

```

effect_size = delta / pooled_var**0.5

# Calcular a amostra mínima por grupo
n_min = zt_ind_solve_power(effect_size=effect_size, alpha=0.05, power=0.80)
n_min = int(round(n_min))

# Avaliar se os tamanhos dos grupos são suficientes
n_controle = df['GRUPO_AB'].value_counts()['Controle']
n_teste = df['GRUPO_AB'].value_counts()['Teste']

teste_suficiente = n_teste >= n_min
controle_suficiente = n_controle >= n_min

{
    "MDE (delta)": f"{delta:.2%}",
    "Amostra mínima por grupo": n_min,
    "Tamanho Controle": n_controle,
    "Tamanho Teste": n_teste,
    "Controle Suficiente": controle_suficiente,
    "Teste Suficiente": teste_suficiente
}

```

```

{'MDE (delta)': '1.00%',
 'Amostra mínima por grupo': 8155,
 'Tamanho Controle': 12308,
 'Tamanho Teste': 109216,
 'Controle Suficiente': True,
 'Teste Suficiente': True}

```

4.3.3 Amostra mínima

Qual seria a amostra mínima desse teste?

```

# Total de público disponível
total_disponivel = n_controle + n_teste

# Função para encontrar a melhor alocação que satisfaz a amostra mínima por grupo
def melhor_distribuicao(total, n_min):
    for controle in range(n_min, total - n_min + 1):
        teste = total - controle
        if teste >= n_min:

```

```

        return controle, teste
    return None, None

melhor_controle, melhor_teste = melhor_distribuicao(total_disponivel, n_min)

{
    "Total disponível": total_disponivel,
    "Amostra mínima por grupo (para delta de 1%)": n_min,
    "Distribuição ideal - Controle": melhor_controle,
    "Distribuição ideal - Teste": melhor_teste
}

```

```

{'Total disponível': 121524,
 'Amostra mínima por grupo (para delta de 1%)': 8155,
 'Distribuição ideal - Controle': 8155,
 'Distribuição ideal - Teste': 113369}

```

Independente dos resultados obtidos nessa fase, você deve continuar a mensurar os seus resultados, pois ao menos podemos interpretar algumas tendências de resultados, o que pode ser base para um novo teste corrigindo o tamanho da amostra.

4.3.4 Análise do resultado do teste

- O período de leitura terminou?
- Sua variável de análise é binária ou contínua?
 - Comprou ou não comprou (ativou ou não, contratou ou não)
 - Valor gasto (valor contratado, valor faturamento)

```

# Criar tabela de contingência entre grupo e compra
contingencia = pd.crosstab(df['GRUPO_AB'], df['FL_ATIVADO'])
contingencia

```

	FL_ATIVADO	
	0	1
GRUPO_AB		
Controle	6158	6150
Teste	49157	60059

```
# Aplicar o teste do qui-quadrado -- Verifique se esse é o teste mais adequado para os tipos
chi2, p, dof, expected = chi2_contingency(contingencia)
```

Por que o valor de p é tão amado e odiado por muita gente. Me convenceram que é muito bom, mas não faz milagre.

```
# Exibir resultados
contingencia, p
```

```
(FL_ATIVADO      0      1
GRUPO_AB
Controle      6158    6150
Teste      49157    60059,
2.979975996279689e-26)
```

```
# considere um alpha para sua área de rejeição
alpha = 0.05
```

```
if p < alpha:
    print(' Resultado Estatisticamente Significativo: Existe diferença real entre os grupos.
else:
    print(' Resultado NÃO Estatisticamente Significativo: Não existe evidência suficiente pa
```

Resultado Estatisticamente Significativo: Existe diferença real entre os grupos.

4.3.5 Delta Conversão

É a diferença entre os percentuais de conversão do grupo de teste e controle

```
taxas = df.groupby('GRUPO_AB')['FL_ATIVADO'].mean()
taxas
```

```
GRUPO_AB
Controle      0.499675
Teste         0.549910
Name: FL_ATIVADO, dtype: float64
```

```
# Calcular e formatar o delta de taxa de conversão entre Teste e Controle
delta_taxa_conversao = taxas['Teste'] - taxas['Controle']

# Reformatar delta como pontos percentuais (p.p.)
delta_taxa_formatado_pp = f"{delta_taxa_conversao * 100:.2f} p.p."

# Exibir com print
print(f"Diferença absoluta na taxa de conversão (Delta): {delta_taxa_formatado_pp}")
```

Diferença absoluta na taxa de conversão (Delta): 5.02 p.p.

4.3.6 Lift

É o ganho percentual que foi obtido com essa ação.

```
lift_conversao = (taxas['Teste'] - taxas['Controle']) / taxas['Controle']
lift_conversao

# Formatar lift de conversão como percentual com 2 casas decimais
lift_conversao_percentual = f"{lift_conversao * 100:.2f}%"
lift_conversao_percentual
```

'10.05%'

4.3.7 Incremento de contas

Pelo fato de ter feito o teste, quanto de contas vieram de

```
# Calcular o tamanho do público de teste
publico_teste = df[df['GRUPO_AB'] == 'Teste'].shape[0]

# Calcular o incremento de contas
incremento_contas = publico_teste * (taxas['Teste'] - taxas['Controle'])

# Arredondar o incremento
incremento_final = int(round(incremento_contas))

# Verificar se o teste foi positivo
resultado_incremento = (
```

```

    f"{incremento_final} contas a mais por causa do teste" if incremento_final > 0
    else "0 teste não gerou incremento de contas"
)

resultado_incremento

```

'5486 contas a mais por causa do teste'

4.3.8 Incremento de gasto

Quanto a mais o grupo de teste gastou devido esse estímulo.

```

# Calcular gasto médio entre grupos
gasto_medio = df.groupby('GRUPO_AB')['VALOR_GASTO'].mean()

# Calcular delta gasto: diferença entre gasto médio do Teste e do Controle
delta_gasto = gasto_medio['Teste'] - gasto_medio['Controle']

# Número de clientes convertidos no grupo Controle
conversoes_controle = df[df['GRUPO_AB'] == 'Controle']['FL_ATIVADO'].sum()

# Incremento estimado de gasto
incremento_gasto = delta_gasto * conversoes_controle

#delta_gasto, incremento_gasto
# Usar print para exibir cada linha separadamente
print("Resultados do impacto financeiro no experimento:\n")
print(f"Delta de Gasto Médio (Teste - Controle): R$ {delta_gasto:,.2f}".replace(",", "X").replace(".", "Y"))
print(f"Incremento de Gasto Total (base Controle): R$ {incremento_gasto:,.2f}".replace(",", "X").replace(".", "Y"))

```

Resultados do impacto financeiro no experimento:

Delta de Gasto Médio (Teste - Controle): R\$ 143,31
 Incremento de Gasto Total (base Controle): R\$ 881.357,95

4.3.9 Incremento de faturamento

Os clientes que vieram a mais por causa do experimento também contribuem para o faturamento, logo precisamos incluí-los:

Incremento de faturamento = Incremento de Contas * Gasto Médio Controle + Incremento de Gasto

```
# Reutilizando variáveis já calculadas
gasto_medio_controle = gasto_medio['Controle'] # gasto médio no grupo Controle
gasto_medio_teste = gasto_medio['Teste'] # gasto médio no grupo Controle

# Incremento total de faturamento = contas a mais * gasto médio + incremento de gasto
incremento_faturamento = incremento_final * gasto_medio_controle + incremento_gasto

# Formatar resultado para apresentação
print(f"Incremento Total de Faturamento: R$ {incremento_faturamento:,.2f}".replace(",", "X"))
```

Incremento Total de Faturamento: R\$ 8.388.591,06

4.3.10 Análise da variável contínua

```
metrica = 'VALOR_GASTO'

# Separar os dados por grupo
grupo_controle = df[df['GRUPO_AB'] == 'Controle'][metrica]
grupo_teste = df[df['GRUPO_AB'] == 'Teste'][metrica]

# Realizar o teste-t (comparação das médias)
t_stat, p_valor = ttest_ind(grupo_teste, grupo_controle)

# Avaliação dos resultados
alpha = 0.05
print(f'Média do grupo Controle: {grupo_controle.mean():.2f}')
print(f'Média do grupo Teste: {grupo_teste.mean():.2f}')
print(f'p-valor do teste: {p_valor:.4f}')

if p_valor < alpha:
    print(' Resultado Estatisticamente Significativo: Existe diferença real entre os grupos.')
else:
    print(' Resultado NÃO Estatisticamente Significativo: Não existe evidência suficiente pa
```

Média do grupo Controle: 1368.43

Média do grupo Teste: 1511.74

p-valor do teste: 0.0000

Resultado Estatisticamente Significativo: Existe diferença real entre os grupos.

4.4 Avaliação completa dos resultados

```
qtde_teste = df[df['GRUPO_AB'] == 'Teste'].shape[0]
qtde_controle = df[df['GRUPO_AB'] == 'Controle'].shape[0]
conv_teste = taxas['Teste']
conv_controle = taxas['Controle']

hipotese_conv = "Rejeita H - Existe Diferença" if p < 0.05 else "Aceita H - Não Existe Diferença"
hipotese_gasto = "Rejeita H - Existe Diferença" if p_valor < 0.05 else "Aceita H - Não Existe Diferença"

# Avaliação simples da qualidade do resultado
def classifica_resultado(delta_conv, delta_gasto, pval_conv, pval_gasto, incremento_faturamento):
    aval = []

    if p < 0.05 and delta_conv > 0:
        aval.append(" Conversão melhor e significativa")
    elif delta_conv > 0:
        aval.append(" Conversão melhor, mas não significativa")
    else:
        aval.append(" Conversão pior ou igual")

    if p_valor < 0.05 and delta_gasto > 0:
        aval.append(" Gasto médio maior e significativo")
    elif delta_gasto > 0:
        aval.append(" Gasto médio maior, mas não significativo")
    else:
        aval.append(" Gasto médio menor ou igual")

    if incremento_faturamento > 0:
        aval.append(" Incremento financeiro positivo")
    else:
        aval.append(" Sem impacto financeiro")

    return " | ".join(aval)

avaliacao_geral = classifica_resultado(delta_taxa_conversao, delta_gasto, p, p_valor, incremento_faturamento)

# Tabela resumo com avaliação geral
tabela_resumo_completa = pd.DataFrame({
```

```

'Métrica': [
    'Qtde Teste', 'Qtde Controle',
    'Conversão Teste', 'Conversão Controle', 'Delta Conversão', 'Lift',
    'Resultado Teste Hipótese Conversão', 'Incremento de Contas',
    'Gasto Médio Teste', 'Gasto Médio Controle', 'Delta Gasto',
    'Resultado Teste Hipótese Gasto', 'Incremento de Gasto',
    'Incremento de Faturamento', 'Avaliação Geral'
],
'Resultado': [
    qtde_teste, qtde_controle,
    f"{conv_teste:.2%}", f"{conv_controle:.2%}", f"{delta_taxa_conversao * 100:.2f} p.p.",
    hipotese_conv, incremento_final,
    f"R$ {gasto_medio_teste:,.2f}".replace(",", "X").replace(".", ",").replace("X", "."),
    f"R$ {gasto_medio_controle:,.2f}".replace(",", "X").replace(".", ",").replace("X", "."),
    f"R$ {delta_gasto:,.2f}".replace(",", "X").replace(".", ",").replace("X", "."),
    hipotese_gasto,
    f"R$ {incremento_gasto:,.2f}".replace(",", "X").replace(".", ",").replace("X", "."),
    f"R$ {incremento_faturamento:,.2f}".replace(",", "X").replace(".", ",").replace("X", "."),
    avaliacao_geral
]
})

# Como Excel
tabela_resumo_completa.to_excel("Mensuracao_TestesAB.xlsx", index=False)

tabela_resumo_completa

```

	Métrica	Resultado
0	Qtde Teste	109216
1	Qtde Controle	12308
2	Conversão Teste	54.99%
3	Conversão Controle	49.97%
4	Delta Conversão	5.02 p.p.
5	Lift	10.05%
6	Resultado Teste Hipótese Conversão	Rejeita H - Existe Diferença
7	Incremento de Contas	5486
8	Gasto Médio Teste	R\$ 1.511,74
9	Gasto Médio Controle	R\$ 1.368,43
10	Delta Gasto	R\$ 143,31
11	Resultado Teste Hipótese Gasto	Rejeita H - Existe Diferença
12	Incremento de Gasto	R\$ 881.357,95

	Métrica	Resultado
13	Incremento de Faturamento	R\$ 8.388.591,06
14	Avaliação Geral	Conversão melhor e significativa Gasto m...

4.4.1 Qual decisão tomar?

```
# Reescrevendo a função classifica_resultado com inserção da verificação da suficiência da amostra

def classifica_resultado_com_amostra(delta_conv, delta_gasto, p, p_valor, incremento_faturamento):
    aval = []

    # Verificação de conversão
    if not (teste_suf and controle_suf):
        aval.append(" Amostras insuficientes para avaliar conversão")
    elif p < 0.05 and delta_conv > 0:
        aval.append(" Conversão melhor e significativa")
    elif delta_conv > 0:
        aval.append(" Conversão melhor, mas não significativa")
    else:
        aval.append(" Conversão pior ou igual")

    # Verificação de gasto
    if p_valor < 0.05 and delta_gasto > 0:
        aval.append(" Gasto médio maior e significativo")
    elif delta_gasto > 0:
        aval.append(" Gasto médio maior, mas não significativo")
    else:
        aval.append(" Gasto médio menor ou igual")

    # Verificação de faturamento
    if incremento_faturamento > 0:
        aval.append(" Incremento financeiro positivo")
    else:
        aval.append(" Sem impacto financeiro")

    return " | ".join(aval)
```

```

# Calcular avaliação com variáveis existentes
avaliacao_completa = classifica_resultado_com_amostra(
    delta_taxa_conversao, delta_gasto, p, p_valor,
    incremento_faturamento, controle_suficiente, teste_suficiente
)

# Reavaliar a classificação anterior com base na decisão da tabela interpretativa
# Vamos mapear o resultado da função classifica_resultado_com_amostra para a decisão final

def decisao_final(avaliacao_texto):
    amostra_ok = "insuficientes" not in avaliacao_texto
    conversao_ok = "Conversão melhor e significativa" in avaliacao_texto
    gasto_ok = "Gasto médio maior e significativo" in avaliacao_texto

    # Definir a linha da tabela com base na combinação de flags
    if amostra_ok and conversao_ok and gasto_ok:
        return " Resultados estatisticamente confiáveis. Pode fazer rollout com segurança."
    elif amostra_ok and conversao_ok and not gasto_ok:
        return " Conversão positiva e confiável, mas impacto financeiro incerto. Teste compl
    elif amostra_ok and not conversao_ok and gasto_ok:
        return " Conversão estável, mas há aumento de gasto. Reavaliar se isso é desejável."
    elif amostra_ok and not conversao_ok and not gasto_ok:
        return " Sem evidências de ganho. Não prosseguir com rollout."
    elif not amostra_ok and conversao_ok and gasto_ok:
        return " Indicadores promissores, mas resultados frágeis estatisticamente. Aumentar
    elif not amostra_ok and conversao_ok and not gasto_ok:
        return " Conversão aparente, mas não confiável. Repetir experimento com mais dados."
    elif not amostra_ok and not conversao_ok and gasto_ok:
        return " Gasto parece maior, mas não confiável. Não tomar decisão ainda."
    elif not amostra_ok and not conversao_ok and not gasto_ok:
        return " Nada é significativo e a amostra é fraca. Não prosseguir."
    else:
        return " Cenário não previsto. Revisar avaliação."

# Aplicar a função de decisão
decisao_experimento = decisao_final(avaliacao_completa)

print(avaliacao_completa)
print(decisao_experimento)

```

Conversão melhor e significativa | Gasto médio maior e significativo | Incremento financeiro
 Resultados estatisticamente confiáveis. Pode fazer rollout com segurança.

4.4.2 Tabela de avaliação dos resultados

Guia para os possíveis resultados que você pode obter!

Amostra Suficiente	Conversão Significativa	Gasto Significativo	Interpretação Final
Sim	Sim	Sim	Resultados estatisticamente confiáveis. Pode fazer rollout com segurança.
Sim	Sim	Não	Conversão positiva e confiável, mas impacto financeiro incerto. Teste complementar recomendado.
Sim	Não	Sim	Conversão estável, mas há aumento de gasto. Reavaliar se isso é desejável.
Sim	Não	Não	Sem evidências de ganho. Não prosseguir com rollout.
Não	Sim	Sim	Indicadores promissores, mas resultados frágeis estatisticamente. Aumentar amostra.
Não	Sim	Não	Conversão aparente, mas não confiável. Repetir experimento com mais dados.
Não	Não	Sim	Gasto parece maior, mas não confiável. Não tomar decisão ainda.
Não	Não	Não	Nada é significativo e a amostra é fraca. Não prosseguir.

5 Analisando diversos perfis

ou diversas campanhas em um resumo.

Agora que você chegou até aqui, acho que posso te dar uma boa notícia! Os indicadores analíticos campanha, público, quantidade de teste e controle e as quantidades de conversão, costumam vir calculados, pois é um processo que pode ser automatizado via banco de dados.

Com isso, cada linha da sua tabela pode representar uma campanha diferente, ou uma segmentação de público diferente dentro da mesma!

Nesse exemplo aplicado, irei seguir com quebras de público, onde quero testar diferenças entre conversões de taxas de empréstimos diferentes. Um teste A/B raiz, afinal, todos foram abordados, mas receberam ofertas diferentes, se aplicamos em marketing, seriam ofertas e/ou banners diferentes para cada público

5.1 Um pouco mais de contexto

*dados fictícios

Esses resultados foram simulados a partir de uma atividade de pricing, onde foram usados dois modelos para caracterizar os grupos de maneiras comparáveis.

- **MODELO 1:** Risco de realizar essa operação
- **MODELO 2:** Probabilidade do cliente aceitar a oferta

5.1.1 Import das bibliotecas

```
import pandas as pd
from statsmodels.stats.proportion import proportions_ztest
from scipy.stats import ttest_ind_from_stats
import numpy as np
import warnings

# Suprimir apenas RuntimeWarnings
warnings.filterwarnings("ignore", category=RuntimeWarning)
```

```
# Carregar a planilha com colunas a serem completadas
df = pd.read_excel("./diversos_grupos_calculo.xlsx")
df.head()
```

	MODELO 1	MODELO2	Taxa Teste	Taxa Controle	Qtde Teste	Qtde Controle	Qtde Conversao T
0	BAIXO	BAIXO	0.0299	0.0399	21996	197964	1979
1	BAIXO	ALTO	0.0399	0.0499	31259	281331	1562
2	MÉDIO	BAIXO	0.0499	0.0599	36027	324243	1801
3	MÉDIO	ALTO	0.0599	0.0699	81498	733482	814
4	ALTO	BAIXO	0.0699	0.0799	57985	521865	4058

5.1.2 Pró-Memória

Agora vamos passar por todos os cálculos feitos no capítulo anterior:

- Conversão e Taxas
- Gasto Médio
- Incrementos
- Testes de hipóteses para avaliar a significancia dos resultados
- Avaliação Final

```
# Função para enriquecer o dataframe
def enrich_with_proportions(row):
    # Conversões e taxas
    conv_teste = row['Qtde Conversao Teste'] / row['Qtde Teste'] if row['Qtde Teste'] > 0 else 0
    conv_controle = row['Qtde Conversao Controle'] / row['Qtde Controle'] if row['Qtde Controle'] > 0 else 0
    delta_conv = conv_teste - conv_controle
    lift_conversao = (conv_teste - conv_controle) / conv_controle if conv_controle > 0 else 0
    lift_conversao_percentual = lift_conversao * 100

    # Gasto médio como proporção = Faturamento / Qtde Conversões
    faturamento_teste = row['Faturamento Teste']
    faturamento_controle = row['Faturamento Controle']

    gasto_medio_teste = faturamento_teste / row['Qtde Conversao Teste'] if row['Qtde Conversao Teste'] > 0 else 0
    gasto_medio_controle = faturamento_controle / row['Qtde Conversao Controle'] if row['Qtde Conversao Controle'] > 0 else 0
    delta_gasto = gasto_medio_teste - gasto_medio_controle
```

```

# Incrementos
incremento_contas = delta_conv * row['Qtde Teste']
incremento_gasto = delta_gasto * row['Qtde Conversao Teste']
incremento_faturamento = incremento_contas * gasto_medio_controle + incremento_gasto

# Teste de hipótese para conversão (proporções)
if row['Qtde Teste'] > 0 and row['Qtde Controle'] > 0:
    count_conv = [row['Qtde Conversao Controle'], row['Qtde Conversao Teste']]
    nobs_conv = [row['Qtde Controle'], row['Qtde Teste']]
    _, p_conv = proportions_ztest(count_conv, nobs_conv)
else:
    p_conv = np.nan

resultado_conv = "Rejeita H" if p_conv < 0.05 and delta_conv > 0 else "Aceita H"

# Teste de hipótese para gasto (proporções também, pois gasto médio é faturamento/conversão)
if row['Qtde Conversao Controle'] > 0 and row['Qtde Conversao Teste'] > 0:
    count_gasto = [faturamento_controle, faturamento_teste]
    nobs_gasto = [row['Qtde Conversao Controle'], row['Qtde Conversao Teste']]
    _, p_gasto = proportions_ztest(count_gasto, nobs_gasto)
else:
    p_gasto = np.nan

resultado_gasto = "Rejeita H" if p_gasto < 0.05 and delta_gasto > 0 else "Aceita H"

# Avaliação final (tabela de decisão)
amostra_suficiente = row['Qtde Teste'] >= 30 and row['Qtde Controle'] >= 30
conv_significativa = p_conv < 0.05 if not np.isnan(p_conv) else False
gasto_significativo = p_gasto < 0.05 if not np.isnan(p_gasto) else False

if amostra_suficiente:
    if conv_significativa and gasto_significativo:
        interpretacao = " Resultados estatisticamente confiáveis. Pode fazer rollout com confiança."
    elif conv_significativa and not gasto_significativo:
        interpretacao = " Conversão positiva e confiável, mas impacto financeiro incerto."
    elif not conv_significativa and gasto_significativo:
        interpretacao = " Conversão estável, mas há aumento de gasto. Reavaliar se isso vale a pena."
    else:
        interpretacao = " Sem evidências de ganho. Não prosseguir com rollout."
else:
    if conv_significativa and gasto_significativo:
        interpretacao = " Indicadores promissores, mas resultados frágeis estatisticamente."
    else:
        interpretacao = " Não há evidências suficientes para tomar uma decisão."

```

```

elif conv_significativa:
    interpretacao = " Conversão aparente, mas não confiável. Repetir experimento com
elif gasto_significativo:
    interpretacao = " Gasto parece maior, mas não confiável. Não tomar decisão ainda
else:
    interpretacao = " Nada é significativo e a amostra é fraca. Não prosseguir."

return pd.Series([
    conv_teste, conv_controle, delta_conv, lift_conversao_percentual,
    gasto_medio_teste, gasto_medio_controle, delta_gasto,
    incremento_contas, incremento_gasto, incremento_faturamento,
    resultado_conv, resultado_gasto, interpretacao
], index=[
    'Conversão Teste', 'Conversão Controle', 'Delta Conversão', 'Lift Conversão (%)',
    'Gasto Médio Teste', 'Gasto Médio Controle', 'Delta Gasto Médio',
    'Incremento Contas', 'Incremento Gasto', 'Incremento Faturamento',
    'Resultado Conversão', 'Resultado Gasto', 'Interpretação Final'
])

# Aplicar a função
df_enriched = df.join(df.apply(enrich_with_proportions, axis=1))
df_enriched

```

	MODELO 1	MODELO2	Taxa Teste	Taxa Controle	Qtde Teste	Qtde Controle	Qtde Conversao T
0	BAIXO	BAIXO	0.0299	0.0399	21996	197964	1979
1	BAIXO	ALTO	0.0399	0.0499	31259	281331	1562
2	MÉDIO	BAIXO	0.0499	0.0599	36027	324243	1801
3	MÉDIO	ALTO	0.0599	0.0699	81498	733482	814
4	ALTO	BAIXO	0.0699	0.0799	57985	521865	4058
5	ALTO	ALTO	0.0799	0.0899	68921	620289	6892
6	ALTISSIMO	BAIXO	0.0899	0.0999	85970	773730	3438
7	ALTISSIMO	ALTO	0.0999	0.1099	98759	888831	6913

Agora que você possui o impacto de cada taxa é só tomar a decisão se fará um roll-out ou não.

```

#Exporta o resultado para o excel
df_enriched.to_excel("TesteABDiversosGrupos.xlsx", index=False)

```

6 Anexos

7 Grupo Controle Universal

7.1 Porque ter um grupo controle?

Simplificando o cenário: imagine que você tem uma pizzaria. Você decide lançar uma superpromoção: **compre uma pizza, ganhe a borda recheada grátis**. Você dispara a campanha para todos os clientes, empolgado. Depois de uma semana, as vendas subiram. Mas... **subiram por causa da promoção ou porque era final de mês e as pessoas naturalmente pedem mais pizza?**

Aí entra o **grupo controle universal** — um grupo fixo de clientes que **nunca recebe campanha nenhuma** e serve como termômetro natural. Segundo Lewis (2004), “o grupo controle é essencial para separar efeitos naturais das ações induzidas pela empresa.” Sem ele, você navega no escuro, sem saber o que realmente funciona.

Além disso, como reforça [Davenport e Harris (2007)] no clássico *Competing on Analytics*, “empresas orientadas por dados não confiam apenas em resultados positivos; elas precisam provar que o ganho foi realmente causado pela ação planejada, e não pelo acaso”. Em outras palavras, sem grupo controle, você pode estar comemorando sorte, não estratégia.

7.2 Como criar o seu grupo controle

Passo 1: Defina quem fica fora.

Escolha uma amostra representativa da sua base (ex.: 5–10%) e **nunca envie campanhas, promoções, estímulos ou ações para eles**. Esse grupo deve ser um retrato fiel do comportamento natural dos clientes.

Por exemplo, se você tem uma fintech com 100 mil clientes, separe 10 mil aleatoriamente para o controle. Não vale pegar só clientes antigos ou só novos — precisa ser uma mistura justa.

Passo 2: Proteja esse grupo.

Como lembra [McCarthy e Perreault (1993)] no livro *Basic Marketing*, “consistência e integridade no experimento são fundamentais para extrair insights válidos”. Ou seja: não quebre seu grupo no meio de campanhas porque achou que precisava bater a meta do mês! Ele precisa ser sagrado.

Passo 3: Documente quem está no grupo.

Registre IDs, perfis e status no seu CRM, e atualize sempre. Uma boa prática é ter flags automáticos no sistema: quando alguém está no controle, o sistema bloqueia envios automaticamente.

Passo 4: Tecnicamente não é tão difícil assim

Existem muitas maneiras de separar uma amostra aleatória de uma população, mas devo admitir que a minha preferida é usar os dígitos do CPF, geralmente já capturamos essa informação no cadastro do cliente e ela é **imutável**, ou seja, não corre o risco de um momento esse cliente ser controle e em outro momento não.

Para ajudar, vamos simular a marcação na base “base_ativados_gasto”, confesso que foi essa técnica que utilizei para criar meus dados

```
# Importar bibliotecas
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import random
import numpy as np
import warnings
warnings.filterwarnings("ignore", category=pd.errors.SettingWithCopyWarning)

# Import da base de dados
df = pd.read_csv('./base_ativados_gasto.csv')

# Como essa base já possui a marcação, irei ignorá-la, e irei gerar um CPF Fictício para cons
df00 = df[['CLIENTNUM']]

# Cria a função que gera CPF
# Função para gerar CPF fictício no formato 'XXX.XXX.XXX-YY'
def gerar_cpf():
    def calcular_digito(cpf_parcial):
        soma = sum(int(digito) * peso for digito, peso in zip(cpf_parcial, range(len(cpf_parcial), 0, -1)))
        resto = soma % 11
        return '0' if resto < 2 else str(11 - resto)

    # Gera os 9 primeiros dígitos aleatórios
    cpf_nove = ''.join([str(random.randint(0, 9)) for _ in range(9)])
    d1 = calcular_digito(cpf_nove)
    d2 = calcular_digito(cpf_nove + d1)
    cpf_completo = cpf_nove + d1 + d2
```

```

    return f'{cpf_completo[:3]}.{cpf_completo[3:6]}.{cpf_completo[6:9]}-{cpf_completo[9:]}'

# Criar a nova coluna com CPF fictício único por linha
df00['cpf_simulado'] = [gerar_cpf() for _ in range(len(df))]

# Exibir as primeiras linhas para confirmação
df00[['CLIENTNUM', 'cpf_simulado']].head()

```

	CLIENTNUM	cpf_simulado
0	1	842.647.765-89
1	2	556.123.788-82
2	3	697.036.801-78
3	4	456.927.260-68
4	5	969.070.833-37

```

# criar aleatório a partir do cpf
# Extrai os 3 últimos dígitos dos 9 primeiros números do CPF simulado
df00['digito_random'] = df00['cpf_simulado'].str.replace('.', '').str.replace('-', '').str[:3]

# Visualiza os dados
df00[['cpf_simulado', 'digito_random']].head()

```

	cpf_simulado	digito_random
0	842.647.765-89	65
1	556.123.788-82	88
2	697.036.801-78	01
3	456.927.260-68	60
4	969.070.833-37	33

```

# Usa os 3 últimos dígitos do CPF (já criados como digito_sorteio)
# Primeiro, cria a coluna como número inteiro
df00['digito_random'] = df00['cpf_simulado'].str.replace('.', '').str.replace('-', '').str[:3].astype(int)

# Define 10% para grupo Controle (ex: quando resto da divisão por 10 for 0)
df00['GRUPO_AB'] = df00['digito_random'].apply(lambda x: 'Controle' if x % 10 == 0 else 'Abordagem')

print(df00['GRUPO_AB'].value_counts(normalize=True).round(3))

```

```
GRUPO_AB
Abordavel    0.901
Controle     0.099
Name: proportion, dtype: float64
```

Pronto, aplique essa regra a cada CPF novo e terá seu controle universal garantido.

7.3 Como aplicar na segmentação de uma campanha

Suponha que você vai rodar uma campanha de cashback segmentada: clientes com alto gasto no cartão recebem 5% de volta. Você pode dividir:

- Grupo A: clientes elegíveis que **recebem a campanha**;
- Grupo B: clientes elegíveis que **não recebem a campanha** (grupo controle universal específico);

Como destacam [Manzi (2012)] em *Uncontrolled*, “os controles universais são como vigias constantes: eles mostram mudanças de fundo que você nunca perceberia olhando apenas para os testes específicos”.

Fique atento ao fluxo de segmentação e marcação da campanha




Figure 7.1: Fluxo de marcação do grupo controle universal

Espero que agora você se sinta preparado para encarar a mensuração de testes sem receios!!!

Referências

- Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., & Scott, S. L. (n.d.). *CausalImpact* [Manual online]. Google. Recuperado em 1 de maio de 2025, de <https://google.github.io/CausalImpact/>
- Davenport, T. H., & Harris, J. G. (2007). *Competing on analytics: The new science of winning*. Harvard Business Press.
- Gallo, A. (2017). *A Refresher on Statistical Significance*. Harvard Business Review.
- Kohavi, R., & Thomke, S. (2017). *The Surprising Power of Online Experiments*. Harvard Business Review.
- Lewis, R. A. (2004). *Estimation of treatment effects in digital experiments*. SSRN Electronic Journal. <https://doi.org/10.2139/ssrn.1686122>
- Manzi, J. (2012). *Uncontrolled: The surprising payoff of trial-and-error for business, politics, and society*. Basic Books.
- McCarthy, E. J., & Perreault, W. D. (1993). *Basic marketing: A global-managerial approach* (11th ed.). Irwin.
- Seabold, S., & Perktold, J. (n.d.). *NormalIndPower* [Manual online]. Statsmodels. Recuperado em 1 de maio de 2025, de <https://www.statsmodels.org/dev/generated/statsmodels.stats.power.NormalIndPower.html>

Contato

[Linkedin](#)

Entre em contato pelo gabriela.macedo@fgv.edu.br.

Confira o [repositório no GitHub](#) para mais detalhes.